

정신건강 트렌드 및 인식 분석

김우석

1. 프로젝트 배경

정신 건강 문제의 중요성:

- 정신 질환은 현대 사회에서 점점 더 큰 문제로 떠오르고 있으며, 특히 우울증, 불안장애 등은 개인과 사회에 심각한 영향을 미침.

인터넷 환경에서의 검색 데이터:

- 사람들은 자신의 건강 상태를 파악하거나 정보 탐색을 위해 인터넷 검색을 자주 이용함.
- 정신질환 데이터와, 검색 데이터를 분석하면 사회적 관심사, 인식 변화, 질병에 대한 경향성을 파악할 수 있음.

데이터 분석의 가치:

- 정신질환 관련 검색량과 실제 환자 데이터를 비교 분석함으로써 사회적 인식 변화와 실제 의료 서비스 이용 간의 상관관계를 탐구 가능.

2. 프로젝트 목적

정신질환 데이터와 검색 트렌드 데이터 분석 및 비교:

- 정신질환 관련 검색량의 연도별 증가 추세를 파악하고, 이를 실제 환자 데이터와 비교하여 인식 변화 및 실제 의료 서비스 이용 간의 상관관계를 분석.

질병별, 연령별, 지역별 패턴 분석:

- 특정 질환의 성별, 연령별, 지역별 발생률 등 어떤 패턴을 가지고 있는지 분석.

3. 데이터 개요

사용 데이터 1 : 정신질환 관련 의료 데이터

- 출처: 건강보험심사평가원
- 내용: 정신질환(우울증,불면증,조현병 등)에 대한 연도별, 지역별, 연령별 환자 수 데이터
- 기간: 2018 년부터 2023 년까지
- 형태: 진료 건수, 환자 수, 지역 및 연령대별 상세 데이터
- 목적: 실제 의료 서비스 이용 현황 및 추세 분석

사용 데이터 2 : 네이버데이터랩 검색 트렌드 데이터

- 출처: 네이버 데이터랩
- 내용: 정신질환에 대한 검색 트렌드 데이터
- 기간: 2018 년부터 2023 년까지
- 형태: 날짜별 검색량(정규화된 상대적 값)
- 목적: 정신질환에 대한 대중의 관심도 변화 분석

4. 데이터 탐색 및 전처리.

- 정신질환 데이터셋의 기본정보(2018~2022 년 데이터, 2023 년 데이터 총 2 개의 파일)

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

import os

data1 = pd.read_csv('/content/시군구 성별 연령별 주요 정신질환 통계
2018~2022.csv', encoding='cp949')
data2 = pd.read_csv('/content/건강보험심사평가원_시군구별 성별 연령군별 주요
정신질환 진료 통계 2023.csv', encoding='cp949')

print(data1.shape)
print(data2.shape)
print("-----")
print(data1.info())
print(data2.info())
```

```
(165000, 9)
(33506, 9)
-----
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 165000 entries, 0 to 164999
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   진료년도    165000 non-null  int64
1   상병구분    165000 non-null  object
2   시도       165000 non-null  object
3   시군구      165000 non-null  object
4   성별       165000 non-null  object
5   연령구분    165000 non-null  object
6   환자수      165000 non-null  int64
7   입내원일수  165000 non-null  int64
8   요양급여비용 165000 non-null  int64
dtypes: int64(4), object(5)
memory usage: 11.3+ MB
None
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 33506 entries, 0 to 33505
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   진료년도    33506 non-null  int64
1   상병구분    33506 non-null  object
2   시도       33506 non-null  object
3   시군구      33506 non-null  object
4   성별       33506 non-null  object
5   연령군      33506 non-null  object
6   환자수      33506 non-null  int64
7   입내원일수  33506 non-null  int64
8   요양급여비용총액 33506 non-null  int64
dtypes: int64(4), object(5)
memory usage: 2.3+ MB
None
-----
```

- 정신질환 데이터셋의 행과 열, 데이터 확인

```
data1.head(10)
```

	진료년도	상별구분	시도	시군구	성별	연령구분	환자수	입내원일수	요양급여비용
0	2018	ADHD	서울	강남구	남	0~9세	437	3330	188836790
1	2018	ADHD	서울	강남구	남	10~19세	1111	8869	563498480
2	2018	ADHD	서울	강남구	남	20~29세	456	3485	213248290
3	2018	ADHD	서울	강남구	남	30~39세	174	1357	72761750
4	2018	ADHD	서울	강남구	남	40~49세	55	357	21611080
5	2018	ADHD	서울	강남구	남	50~59세	20	131	8719580
6	2018	ADHD	서울	강남구	남	60~69세	0	0	0
7	2018	ADHD	서울	강남구	남	70~79세	0	0	0
8	2018	ADHD	서울	강남구	남	80~89세	0	0	0
9	2018	ADHD	서울	강남구	남	90~99세	0	0	0

```
data2.head(10)
```

	진료년도	상별구분	시도	시군구	성별	연령구분	환자수	입내원일수	요양급여비용총액
0	2023	ADHD	서울	강남구	남	0~9세	980	6448	519912600
1	2023	ADHD	서울	강남구	남	10~19세	2295	17250	1509286940
2	2023	ADHD	서울	강남구	남	20~29세	1431	10151	1160302970
3	2023	ADHD	서울	강남구	남	30~39세	1137	8171	1033772760
4	2023	ADHD	서울	강남구	남	40~49세	312	2168	260667860
5	2023	ADHD	서울	강남구	남	50~59세	83	449	45767940
6	2023	ADHD	서울	강남구	남	60~69세	0	0	0
7	2023	ADHD	서울	강남구	남	70~79세	0	0	0
8	2023	ADHD	서울	강남구	남	80~89세	0	0	0
9	2023	ADHD	서울	강남구	남	90~99세	0	0	0

- 데이터 전처리 및 병합

```
# data1,과 data2의 열 이름이 다름으로 동일한 컬럼 이름으로 맞춤
data2.columns = data1.columns

# 결과 확인
print("-----")
print(data1.columns)
print(data2.columns)

print("-----")
print(data1.columns == data2.columns)

# 두 데이터프레임 이어붙여 2018~2023년 모든 데이터를 사용
combined_data = pd.concat([data1, data2], ignore_index=True)

print("-----")

# 결과 확인
print(combined_data.head())
print(combined_data.tail())
```

```
Index(['진료년도', '상별구분', '시도', '시군구', '성별', '연령구분', '환자수', '입내원일수', '요양급여비용'], dtype='object')
Index(['진료년도', '상별구분', '시도', '시군구', '성별', '연령구분', '환자수', '입내원일수', '요양급여비용'], dtype='object')

[ True  True  True  True  True  True  True  True  True]

진료년도 상별구분 시도 시군구 성별 연령구분 환자수 입내원일수 요양급여비용
0  2018  ADHD  서울  강남구  남   0~9세   437   3330  188836790
1  2018  ADHD  서울  강남구  남  10~19세  1111   8869  563498480
2  2018  ADHD  서울  강남구  남  20~29세   456   3485  213248290
3  2018  ADHD  서울  강남구  남  30~39세   174   1357   72761750
4  2018  ADHD  서울  강남구  남  40~49세    55    357   21611080
진료년도 상별구분 시도 시군구 성별 연령구분 환자수 입내원일수 요양급여비용
198501  2023  조현병  세종  세종시  여  60~69세   31   1067   76984850
198502  2023  조현병  세종  세종시  여  70~79세   13    429   30558940
198503  2023  조현병  세종  세종시  여  80~89세    0     0         0
198504  2023  조현병  세종  세종시  여  90~99세    0     0         0
198505  2023  조현병  세종  세종시  여 100세 이상    0     0         0
```

5. 데이터 시각화 및 분석

- 시간의 흐름에 따른 환자 수 분석

```
# 연도별 환자수 집계
yearly_summary =
combined_data.groupby('진료년도')['환자수'].sum().reset_index()

# 선 그래프와 추세선
plt.figure(figsize=(10, 6))

# x와 y 값 정의
x = yearly_summary['진료년도'].astype(int) # 연도
y = yearly_summary['환자수'] # 환자 수


# 실제 데이터 선 그래프
plt.plot(x, y, marker='o', label='환자수', color='blue')

# 추세선 (1 차 회귀)
z = np.polyfit(x, y, 1) # 1 차 다항식 회귀
p = np.poly1d(z)
plt.plot(x, p(x), linestyle='--', color='red', label='추세선')

# Y축 숫자 포맷 함수 정의
def format_y(value, tick_number):
    return f"{int(value):,}" # 천 단위 콤마 추가

# Y축 숫자 포맷 적용
ax = plt.gca()
ax.yaxis.set_major_formatter(FuncFormatter(format_y))

# 그래프 설정
plt.title('연도별 환자수와 추세선', fontsize=16)
plt.xlabel('진료년도', fontsize=12)
plt.ylabel('환자수', fontsize=12)
plt.legend()
plt.tight_layout()
plt.show()
```



결과 : 연도별 환자수와 추세선을 보면 환자 수가 꾸준히 증가하는 추세를 보인다.


추가 인사이트: 사회적 인식 개선으로 인해 정신질환에 대한 낙인이 줄어들면서 진료받는 환자 수가 증가했을 가능성이 있다.

- 성별 환자수 비율 분석

```
# 성별별 환자수 합계
gender_total = combined_data.groupby('성별')['환자수'].sum()

# 도넛 차트
fig, ax = plt.subplots(figsize=(8, 8))
wedges, texts, autotexts = ax.pie(
    gender_total,
    labels=gender_total.index,
    autopct=lambda pct: f'{int(pct * sum(gender_total) / 100):,}명', # 실제 환자수 표시
    startangle=90,
    colors=['skyblue', 'pink'],
    wedgeprops=dict(width=0.4, edgecolor='w')
)
plt.title('성별 환자수 비율', fontsize=16)
plt.tight_layout()
plt.show()
```

성별 환자수 비율



결과: 성별 환자수 비율을 보면 여성이 남성보다 더 많은 비율을 차지하고 있다.

추가 인사이트: 이는 여성이 정신건강에 대한 관심과 진단률이 높을꺼라고 추측된다.

- 질환별 성별 환자수 분석

```
# 질환별-성별 환자수 합계
disease_gender = combined_data.groupby(['상별구분',
    '성별'])['환자수'].sum().unstack()


# 그래프 생성
fig, ax = plt.subplots(figsize=(12, 8))
disease_gender.plot(kind='bar', color=['skyblue', 'pink'],
    edgecolor='black', ax=ax)

# Y축 숫자 포맷 함수 정의
def format_y(value, tick_number):
    return f"{int(value):,}"

# Y축 숫자 포맷 적용
ax.yaxis.set_major_formatter(FuncFormatter(format_y))

# 그래프 설정
plt.title('질환별 성별 환자수 비교', fontsize=16)
plt.xlabel('질환 (상별구분)', fontsize=12)
plt.ylabel('환자수', fontsize=12)
plt.xticks(rotation=45)
plt.legend(title='성별', loc='upper right')
plt.grid(axis='y', linestyle='--', linewidth=0.7)
plt.tight_layout()

plt.show()
```



결과: 불면증, 불안장애, 우울증, 조울증, 조현병 등의 질환은 여성 환자 비율이 높다. 반면, ADHD는 남성 환자 비율이 더 높게 나타난다.

- 연령대별 환자수 분석

```
# 연령구분 정렬을 위한 사전 정의
age_order = [
    '0~9 세', '10~19 세', '20~29 세', '30~39 세', '40~49 세', '50~59 세',
    '60~69 세', '70~79 세', '80~89 세', '90~99 세', '100 세 이상'
]

# 연령구분 열을 Categorical 타입으로 변환하여 정렬 순서 지정
combined_data['연령구분'] = pd.Categorical(combined_data['연령구분'],
categories=age_order, ordered=True)

# 연령구분별 환자수 합계 다시 계산
age_group_total = combined_data.groupby('연령구분')['환자수'].sum()


# 그래프 생성
fig, ax = plt.subplots(figsize=(10, 6))
age_group_total.plot(kind='bar', color='skyblue', edgecolor='black',
ax=ax)
```

```
# Y축 숫자 포맷 함수 정의
def format_y(value, tick_number):
    return f"{int(value):,}"

# Y축 숫자 포맷 적용
ax.yaxis.set_major_formatter(FuncFormatter(format_y))

# 그래프 설정
plt.title('연령대별 환자수 비교', fontsize=16)
plt.xlabel('연령구분', fontsize=12)
plt.ylabel('환자수', fontsize=12)
plt.xticks(rotation=45)
plt.grid(axis='y', linestyle='--', linewidth=0.7)
plt.tight_layout()

plt.show()
```



결과: 연령대별 환자수 비교 결과, 중장년층(40~59 세)의 환자 비율이 가장 높게 나타난다.

추가 인사이트: 중장년층은 직장 및 가정 내 스트레스, 경제적 부담 등으로 인해 정신질환 발생률이 높아질 거라고 추측.

- 연령대별 특정 질환의 발생률 분석

```
# 연령구분 정렬을 위한 사전 정의
age_order = [
    '0~9 세', '10~19 세', '20~29 세', '30~39 세', '40~49 세', '50~59 세',
    '60~69 세', '70~79 세', '80~89 세', '90~99 세', '100 세 이상'
]

# 연령구분 열을 Categorical 타입으로 변환하여 정렬 순서 지정
combined_data['연령구분'] = pd.Categorical(combined_data['연령구분'],
categories=age_order, ordered=True)

# 연령대별-질환별 환자수 합계
age_disease_data = combined_data.groupby(['연령구분',
'상별구분'])['환자수'].sum().unstack().fillna(0)


# 그래프 생성
fig, ax = plt.subplots(figsize=(12, 8))
age_disease_data.plot(kind='bar', stacked=True, colormap='viridis',
ax=ax)

# Y 축 숫자 포맷 함수 정의
def format_y(value, tick_number):
    return f"{int(value):,}"

# Y 축 숫자 포맷 적용
ax.yaxis.set_major_formatter(FuncFormatter(format_y))

# 그래프 설정
plt.title('연령대별 특정 질환의 발생률', fontsize=16)
plt.xlabel('연령구분', fontsize=12)
plt.ylabel('환자수', fontsize=12)
plt.xticks(rotation=45)
plt.legend(title='질환', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(axis='y', linestyle='--', linewidth=0.7)
plt.tight_layout()

plt.show()
```



결과: ADHD 는 성인이 되면서 환자 수가 크게 감소하는 경향을 보인다. 우울증은 20대에서 가장 높은 비율을 기록하며, 이는 사회 진입기의 스트레스와 관련이 있을 수 있다.

- 지역별 차이 분석

```
# 환자수가 많은 상위 10 개 지역
top_regions =
combined_data.groupby('시군구')['환자수'].sum().nlargest(10).index
filtered_data = combined_data[combined_data['시군구'].isin(top_regions)]

# 연도별-지역별 환자수 피벗 테이블
region_year_data = filtered_data.pivot_table(index='시군구',
columns='진료년도', values='환자수', aggfunc='sum').fillna(0)

# 연도별 환자수 변화 히트맵
plt.figure(figsize=(12, 8))
ax = sns.heatmap(region_year_data, annot=True, fmt=".0f",
cmap='YlGnBu', linewidths=0.5)

# x 축 레이블 회전
plt.xticks(rotation=45)
```

```
# 제목 및 축 레이블 설정
plt.title('연도별 상위 10개 지역 환자수 히트맵')
plt.xlabel('진료년도')
plt.ylabel('시군구')

plt.tight_layout()
plt.show()

# 환자수가 가장 많은 지역 출력
most_patients_region = region_year_data.sum(axis=1).idxmax()
most_patients_count = region_year_data.sum(axis=1).max()
print(f"환자수가 가장 많은 지역은 '{most_patients_region}'로, 총 {most_patients_count:,}명입니다.")
```



결과 : 환자 수가 가장 많은 지역은 강남구로, 총 470,983 명을 기록했다.

추가 인사이트: 강남구는 높은 인구 밀도와 의료 접근성이 우수한 지역으로, 진단 및 치료를 받는 환자 수가 많을 가능성이 있다.

- 시도별 가장 많은 질환과 환자수 분석

```
# 시도별 상병구분별 환자수 집계
region_disease_data = combined_data.groupby(['시도',
'상별구분'])['환자수'].sum().unstack()

# 각 시도별로 가장 많은 환자수를 차지한 질환 및 해당 환자수 추출
region_top_disease = region_disease_data.idxmax(axis=1)
region_top_disease_count = region_disease_data.max(axis=1)

# 데이터프레임 생성
region_disease_summary = pd.DataFrame({
    '최다 질환': region_top_disease,
    '환자수': region_top_disease_count
}).sort_values(by='환자수', ascending=False)

# 상위 10 개 시도 추출
top_region_disease_summary = region_disease_summary.head(10)


# 막대 그래프 생성
fig, ax = plt.subplots(figsize=(12, 8))
bars = ax.bar(
    top_region_disease_summary.index,
    top_region_disease_summary['환자수'],
    color='orange',
    edgecolor='black'
)

# Y 축 숫자 포맷 함수 정의
def format_y(value, tick_number):
    return f"{int(value):,}"

# Y 축 숫자 포맷 적용
ax.yaxis.set_major_formatter(FuncFormatter(format_y))

# 각 막대 위에 질환 이름 추가
for bar, disease in zip(bars, top_region_disease_summary['최다 질환']):
    height = bar.get_height()
    ax.text(
        bar.get_x() + bar.get_width() / 2,
        height + 5000, # 텍스트 위치 (막대 위)
        disease,
        ha='center',
        va='bottom',
        fontsize=10,
        color='black'
    )
```

```
# 제목 및 레이블 설정
plt.title('시도별 가장 많은 질환과 환자수', fontsize=16)
plt.xlabel('시도', fontsize=12)
plt.ylabel('환자수', fontsize=12)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



결과: 대구, 경남, 대전, 전북 지역에서는 불안장애 환자가 가장 많다. 그 외 대부분의 지역에서는 우울증 환자가 가장 높은 비율을 차지한다.

추가 인사이트: 지역별 경제적, 사회적 환경의 차이가 특정 질환 발생률에 영향을 미쳤을 가능성도 있다고 생각한다.


- 질환별 환자수 비율 분석

```
# 질환별 환자수 합계
disease_total =
combined_data.groupby('상별구분')['환자수'].sum().sort_values(ascending=False)

# 파이 차트 생성
plt.figure(figsize=(10, 8))
plt.pie(
    disease_total,
    labels=disease_total.index,
    autopct='%1.1f%%', # 퍼센트 표시
    startangle=90, # 시작 각도
    colors=plt.cm.Set3.colors, # 색상 설정
    wedgeprops={'edgecolor': 'black'} # 경계선 추가
)

# 제목 추가
plt.title('질환별 환자수 비율', fontsize=16)
plt.tight_layout()
plt.show()
```

질환별 환자수 비율



결과 : 우울증, 불안장애, 불면증 환자가 전체 환자 수의 높은 비율을 차지한다.

추가 인사이트: 이들 질환은 현대인의 삶에서 스트레스와 밀접하게 관련되어 있으며, 사회 전반에서의 예방 및 치료 대책이 필요.

사회적 인식과 변화에 대한 추가적인 분석

1. 데이터 수집 및 전처리 과정

- 네이버 검색어 트렌드를 이용.

궁금한 주제어를 설정하고, 하위 주제어에 해당하는 검색어를 콤마(,)로 구분입력해 주세요. 입력한 단어의 추이를 하나로 합산하여 해당 주제가 네이버에서 얼마나 검색되는지 조회할 수 있습니다. 예) 주제어 캠핑 : 캠핑, Camping, 캠핑용품, 겨울캠핑, 캠핑장, 글램핑, 오토캠핑, 캠핑카, 텐트, 캠핑요리

주제어1	<input type="text" value="우울증"/>	<input type="text" value="우울증"/>
주제어2	<input type="text" value="불안장애"/>	<input type="text" value="불안장애"/>
주제어3	<input type="text" value="ADHD"/>	<input type="text" value="adhd"/>
주제어4	<input type="text" value="조현병"/>	<input type="text" value="조현병"/>
주제어5	<input type="text" value="불면증"/>	<input type="text" value="불면증"/>

기간

<input type="button" value="전체"/>	<input type="button" value="1개월"/>	<input type="button" value="3개월"/>	<input type="button" value="1년"/>	<input type="button" value="직접입력"/>	<input type="button" value="일간"/>	
<input type="text" value="2018"/>	<input type="text" value="11"/>	<input type="text" value="30"/>	-	<input type="text" value="2024"/>	<input type="text" value="11"/>	<input type="text" value="30"/>


- 2016년 1월 이후 조회할 수 있습니다.

범위 ☒ 전체 ☒ 모바일 ☒ PC

성별 ☒ 전체 ☒ 여성 ☒ 남성


연령선택 ☒ 전체

☒ ~12 ☒ 13~18 ☒ 19~24 ☒ 25~29 ☒ 30~34 ☒ 35~39 ☒ 40~44 ☒ 45~49 ☒ 50~54 ☒ 55~59 ☒ 60~

 네이버 검색 데이터 조회

주제어를 설정하여 검색량 데이터를 가져올 수 있다.


하지만 기간을 2018 년~2024 년 으로 설정하면 데이터 조회가 잘 안되는 현상 발생



- 우울증 | 우울증
- 불안장애 | 불안장애
- ADHD | adhd
- 조현병 | 조현병
- 불면증 | 불면증

다운로드

문제 해결 : 기간을 1 년씩 잡음으로서 제대로된 검색량 데이터 조회가 가능



위 사진 속 우측 하단에 있는 다운로드 버튼을 눌러 1 년씩 조회한 데이터를 받음.

```
datalab_2023
datalab_2022
datalab_2021
datalab_2020
datalab_2019
datalab_2018
```

< 받은 데이터 목록 >

- 데이터 기본 정보 확인

```
file_path = "/content/datalab_2018.xlsx" # 파일 경로를 실제 위치로 변경

data = pd.read_excel(file_path)
data.head(10)
```

	url	http://datalab.naver.com/keyword/trendResult.naver?hashKey=N_313f152aad2e0be5c6c031f3dba8e537	Unnamed: 2	Unnamed: 3	Unnamed: 4	Unnamed: 5	Unnamed: 6	Unnamed: 7	Unnamed: 8	Unnamed: 9
0	주제	통검	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	범위	합계	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	기간	일간 : 2018-01-01 ~ 2019-01-01	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	성별	전체(여성,남성)	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	연령대	전체	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
5	날짜	우울증	날짜	불안장애	날짜	ADHD	날짜	조현병	날짜	불면증
6	2018-01-01	0.19408	2018-01-01	0.03146	2018-01-01	0.0484	2018-01-01	0.0635	2018-01-01	0.0818
7	2018-01-02	0.22669	2018-01-02	0.03697	2018-01-02	0.06439	2018-01-02	0.11243	2018-01-02	0.11909
8	2018-01-03	0.18988	2018-01-03	0.03408	2018-01-03	0.05988	2018-01-03	0.11604	2018-01-03	0.11961
9	2018-01-04	0.16518	2018-01-04	0.03246	2018-01-04	0.056	2018-01-04	0.30871	2018-01-04	0.12108

위 나온 결과로는 정보 확인이 어려워 직접 파일을 열어서 확인.

	A	B	C	D	E	F	G	H	I	J	K	L
1	url	http://datalab.naver.com/keyword/trendResult.naver?hashKey=N_313f152aad2e0be5c6c031f3dba8e537										
2	주제	통검										
3	범위	합계										
4	기간	일간 : 2018-01-01 ~ 2019-01-01										
5	성별	전체(여성,남성)										
6	연령대	전체										
7	날짜	우울증	날짜	불안장애	날짜	ADHD	날짜	조현병	날짜	불면증		
8	2018-01-01	0.19408	2018-01-01	0.03146	2018-01-01	0.0484	2018-01-01	0.0635	2018-01-01	0.0818		
9	2018-01-02	0.22669	2018-01-02	0.03697	2018-01-02	0.06439	2018-01-02	0.11243	2018-01-02	0.11909		
10	2018-01-03	0.18988	2018-01-03	0.03408	2018-01-03	0.05988	2018-01-03	0.11604	2018-01-03	0.11961		
11	2018-01-04	0.16518	2018-01-04	0.03246	2018-01-04	0.056	2018-01-04	0.30871	2018-01-04	0.12108		
12	2018-01-05	0.16508	2018-01-05	0.0335	2018-01-05	0.05228	2018-01-05	6.81978	2018-01-05	0.11521		
13	2018-01-06	0.15244	2018-01-06	0.03387	2018-01-06	0.05196	2018-01-06	0.49744	2018-01-06	0.09858		
14	2018-01-07	0.16308	2018-01-07	0.03114	2018-01-07	0.04326	2018-01-07	0.19591	2018-01-07	0.09711		
15	2018-01-08	0.17452	2018-01-08	0.04184	2018-01-08	0.05784	2018-01-08	0.12082	2018-01-08	0.13681		
16	2018-01-09	0.17305	2018-01-09	0.03718	2018-01-09	0.06198	2018-01-09	0.10849	2018-01-09	0.13041		
17	2018-01-10	0.15815	2018-01-10	0.03413	2018-01-10	0.06041	2018-01-10	0.08316	2018-01-10	0.12811		
18	2018-01-11	0.15417	2018-01-11	0.03413	2018-01-11	0.05511	2018-01-11	0.07635	2018-01-11	0.12978		
19	2018-01-12	0.15406	2018-01-12	0.03141	2018-01-12	0.05647	2018-01-12	0.08925	2018-01-12	0.11542		
20	2018-01-13	0.13716	2018-01-13	0.03222	2018-01-13	0.04722	2018-01-13	0.08222	2018-01-13	0.08222		

위 파일을 보면 1~6 번행은 데이터의 정보에대한 글로 필요 없음으로 삭제가 필요.

인덱스 재설정.

날짜 열이 중복되어 있기 때문에 중복된 날짜열은 제거 해야 함.

```

# datalab_으로 시작하는 파일 경로 불러오기
file_paths = glob.glob("/content/datalab_*.xlsx") # 경로에 맞게 변경

# 모든 파일을 처리 및 병합
dataframes = []
for file_path in file_paths:
    # 파일 불러오기
    data = pd.read_excel(file_path, skiprows=7)

    # 첫 번째 열 이름을 '날짜'로 설정
    data = data.rename(columns={data.columns[0]: "날짜"})

    # 중복된 날짜 열 제거 (첫 번째 열 제외)
    data = data.loc[:, ~data.columns.duplicated()]

    # 필요 없는 행 삭제 (날짜 이후의 데이터만 유지)
    data = data.iloc[1:].reset_index(drop=True)

    # 날짜 열 변환
    data['날짜'] = pd.to_datetime(data['날짜'], errors='coerce')

    # 검색량 데이터를 숫자로 변환
    for col in data.columns[1:]:
        data[col] = pd.to_numeric(data[col], errors='coerce')

    # 데이터프레임에 추가
    dataframes.append(data)

# 모든 데이터를 하나로 병합
combined_data = pd.concat(dataframes, ignore_index=True)

# 날짜별 데이터 정렬
combined_data = combined_data.sort_values("날짜").reset_index(drop=True)

# 연도별 검색량 합계 계산
combined_data['연도'] = combined_data['날짜'].dt.year
search_columns = [col for col in combined_data.columns if col not in ["날짜", "연도"]]
yearly_search_trends = combined_data.groupby('연도')[search_columns].sum()


# 연도별 전체 검색량 합계 계산
yearly_search_trends['전체 검색량'] = yearly_search_trends.sum(axis=1)

# 2023 년까지만 데이터 필터링
yearly_search_trends = yearly_search_trends[yearly_search_trends.index <= 2023]

```

```
# 결과 출력
print("연도별 검색량 합계 (2023년까지):")
print(yearly_search_trends)

# 시각화: 연도별 검색량 추세 (2023년까지)
plt.figure(figsize=(10, 6))
plt.plot(yearly_search_trends.index, yearly_search_trends['전체 검색량'],
marker='o', color='blue')
plt.title("연도별 검색량 증가 추세 (2023년까지)", fontsize=16)
plt.xlabel("연도", fontsize=12)
plt.ylabel("전체 검색량", fontsize=12)
plt.grid(axis="y", linestyle="--", linewidth=0.7)
plt.tight_layout()
plt.show()
```



결과 : 정신질환에 관련한 키워드 전체 검색량이 증가 하는 추세를 보인다. 이는 사람들이 정신질환을 숨기지 않고, 이를 자연스러운 건강 문제로 받아들이는 분위기가 형성되면서 검색량도 증가했을 가능성이 있다.

- 연도별 환자수의 추세선과 종합하여 분석


```
# 첫 번째 Y 축: 연도별 검색량
color = 'tab:blue'
ax1.set_xlabel('연도', fontsize=12)
ax1.set_ylabel('전체 검색량', color=color, fontsize=12)
ax1.plot(
    yearly_search_trends.index,
    yearly_search_trends['전체 검색량'],
    marker='o',
    label='검색량',
    color=color
)
ax1.tick_params(axis='y', labelcolor=color)
ax1.grid(axis='y', linestyle="--", linewidth=0.7)

# 두 번째 Y 축: 연도별 환자수
ax2 = ax1.twinx() # 두 번째 Y 축 생성
color = 'tab:orange'
ax2.set_ylabel('환자수', color=color, fontsize=12)
ax2.plot(
    yearly_summary['진료년도'],
    yearly_summary['환자수'],
    marker='s',
    linestyle='--',
    label='환자수',
    color=color
)
ax2.tick_params(axis='y', labelcolor=color)

# Y 축 숫자 포맷 적용 (천 단위 콤마)
ax2.yaxis.set_major_formatter(FuncFormatter(lambda x, _:
f"{int(x):,}"))

# 제목 및 범례 설정
fig.suptitle("연도별 검색량과 환자수 추세 비교", fontsize=16)
ax1.legend(loc='upper left')
ax2.legend(loc='upper right')

# 레이아웃 조정 및 출력
plt.tight_layout()
plt.show()
```



결론 :

이러한 결과는 정신건강 문제에 대한 대중의 관심 증가, 의료 접근성 향상과 인터넷 매체등의 영향을 보여준 것이 아닐까 싶다.

그러나 환자 수가 꾸준히 증가하는 것은 사회적 스트레스나 현대 생활방식의 영향을 반영할 가능성이 있으므로, 예방적 접근이 강화되어야 한다고 생각한다.

정신건강 트렌드에 대한 추가적인 분석(국제적 관점)

데이터 : 국가별 정신 건강 관련 통계 데이터 (출처:Kaggle)

- 데이터 기본 정보 확인

Entity	Code	Year	Schizophrenia disorders (share of population) – Sex: Both – Age: Age-standardized	Depressive disorders (share of population) – Sex: Both – Age: Age-standardized	Anxiety disorders (share of population) – Sex: Both – Age: Age-standardized	Bipolar disorders (share of population) – Sex: Both – Age: Age-standardized	Eating disorders (share of population) – Sex: Both – Age: Age-standardized	
0	Afghanistan	AFG	1990	0.223206	4.996118	4.713314	0.703023	0.127700
1	Afghanistan	AFG	1991	0.222454	4.989290	4.702100	0.702069	0.123256
2	Afghanistan	AFG	1992	0.221751	4.981346	4.683743	0.700792	0.118844
3	Afghanistan	AFG	1993	0.220987	4.976958	4.673549	0.700087	0.115089
4	Afghanistan	AFG	1994	0.220183	4.977782	4.670810	0.699898	0.111815
5	Afghanistan	AFG	1995	0.219409	4.978228	4.668100	0.699768	0.108507
6	Afghanistan	AFG	1996	0.218465	4.981489	4.665759	0.699650	0.105269
7	Afghanistan	AFG	1997	0.217286	4.987593	4.665013	0.699597	0.101531
8	Afghanistan	AFG	1998	0.216074	4.996858	4.668240	0.699765	0.098050
9	Afghanistan	AFG	1999	0.215068	5.004257	4.673557	0.700054	0.095723

Entity: 국가명

Code: 국가 코드를 나타내는 열

Year: 연도별 데이터

Schizophrenia: 조현병 환자의 비율

Depressive disorders: 우울증 환자의 비율

Anxiety disorders: 불안 장애 환자의 비율

Bipolar disorders: 양극성 장애 환자의 비율

Eating disorders: 섭식 장애 환자의 비율

- 데이터 전처리

열이름이 "Schizophrenia disorders (share of population) - Sex: Both - Age: Age-standardized" 이와 같이 길기 때문에 열이름을 간단하게 변경 후 작업 진행.

```
new_columns = [
    'Entity', 'Code', 'Year', 'Schizophrenia', 'Depressive disorders',
    'Anxiety disorders', 'Bipolar disorders', 'Eating disorders'
]
data.columns = new_columns # 열 이름 변경

# 열 이름 변경 후 확인
print("Renamed Columns in dataset:")
print(data.columns)
```

```
Renamed Columns in dataset:
Index(['Entity', 'Code', 'Year', 'Schizophrenia', 'Depressive disorders',
       'Anxiety disorders', 'Bipolar disorders', 'Eating disorders'],
      dtype='object')
```

- 데이터 시각화

1. 대륙별 우울증 비율 비교 분석

```
# 대륙별 국가 리스트 정의
continent_dict = {
    'Asia': [
        'China', 'India', 'Japan', 'South Korea', 'Indonesia',
        'Thailand',
        'Philippines', 'Vietnam', 'Malaysia', 'Singapore', 'Pakistan',
        'Bangladesh', 'Sri Lanka', 'Nepal', 'Bhutan', 'Maldives',
        'Mongolia'
    ]
}
```

```

],
    'Europe': [
        'Germany', 'France', 'United Kingdom', 'Italy', 'Spain',
        'Poland',
        'Netherlands', 'Belgium', 'Sweden', 'Norway', 'Denmark',
        'Finland'
    ],
    'Africa': [
        'Nigeria', 'South Africa', 'Ethiopia', 'Egypt', 'Kenya',
        'Tanzania',
        'Uganda', 'Ghana', 'Mozambique', 'Zambia'
    ],
    'South America': [
        'Brazil', 'Argentina', 'Colombia', 'Chile', 'Peru', 'Venezuela',
        'Ecuador', 'Bolivia', 'Paraguay', 'Uruguay'
    ]
}

# 대륙별 필터링 및 평균 계산
continent_data = []
for continent, countries in continent_dict.items():
    filtered_data = data[data['Entity'].isin(countries)]
    avg_depressive = filtered_data['Depressive disorders'].mean()
    continent_data.append({'Continent': continent, 'Average Depressive
Disorders': avg_depressive})

# 대륙별 데이터프레임 생성
continent_df = pd.DataFrame(continent_data)

# 시각화: 대륙별 평균 우울증 비율 비교
fig = px.bar(
    continent_df,
    x='Continent',
    y='Average Depressive Disorders',
    color='Continent',
    title="Average Depressive Disorders by Continent",
    labels={"Continent": "Continent", "Average Depressive Disorders":
"Depressive Disorders (%)"}
)

# 그래프 레이아웃 설정
fig.update_layout(
    xaxis_title="Continent",
    yaxis_title="Depressive Disorders (%)",
    title_font_size=16
)

# 그래프 출력

```

```
fig.show()
```



결과 : 아프리카는 평균 우울증 비율이 가장 높았으며, 유럽은 약 3%로 두 번째로 높았다. 아시아와 남아메리카는 각각 2.5~3%로 상대적으로 낮았다.

2. 아시아 국가별 우울증 비교 분석 시각화

```
import plotly.express as px

# 국가별 우울증 비율 평균 계산
avg_depressive_disorders = data.groupby('Entity')['Depressive disorders'].mean().reset_index()

asia_countries = [
    'China', 'India', 'Japan', 'South Korea', 'Indonesia', 'Thailand',
    'Philippines', 'Vietnam', 'Malaysia', 'Singapore', 'Pakistan',
    'Bangladesh', 'Sri Lanka', 'Nepal', 'Bhutan', 'Maldives',
    'Mongolia'
]

# 아시아 국가 데이터 필터링
asia_data = avg_depressive_disorders[avg_depressive_disorders['Entity'].isin(asia_countries)]

# 우울증 비율 기준으로 순위 계산
asia_data['Rank'] = asia_data['Depressive disorders'].rank(ascending=False)

# 결과 정렬 및 출력
```

```

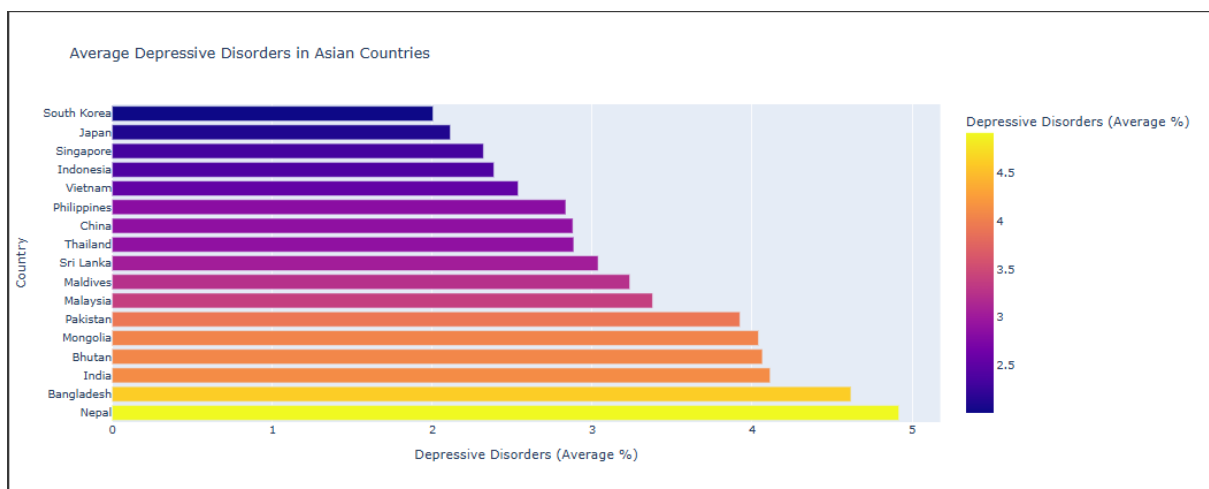
asia_data = asia_data.sort_values(by='Depressive disorders',
ascending=False)
print("Asian Countries by Depressive Disorders:")
print(asia_data)

# 시각화: 수평 막대 그래프 생성
fig = px.bar(
    asia_data,
    x='Depressive disorders',
    y='Entity',
    orientation='h',
    color='Depressive disorders',
    title="Average Depressive Disorders in Asian Countries",
    labels={"Entity": "Country", "Depressive disorders": "Depressive
Disorders (Average %)"})
)

# 그래프 레이아웃 설정
fig.update_layout(
    xaxis_title="Depressive Disorders (Average %)",
    yaxis_title="Country",
    title_font_size=16
)

# 그래프 출력
fig.show()

```



결과: 아시가 국가 중 네팔이 평균 우울증 비율이 가장 높았으며, 방글라데시와 인도가 그 뒤를 이었다. 반면, 대한민국과 일본은 낮은 비율을 기록했다.